

FAST-LIO 论文解读

zlwang 2022.11

摘要

本文是对 FAST-LIO 论文的详细解读，主要包含公式的详细推导以及一些个人理解，如有错误欢迎批评指正。

目录

1	Abstract	1
2	Introduction	1
3	Methodology	1
3.1	Framework Overview	1
3.2	System description	2
3.2.1	\oplus / \ominus operator	2
3.2.2	Continuous model	4
3.2.3	Discrete model	6
3.2.4	Discrete model	6
3.3	State Estimation	7
3.3.1	Forward Propagation	8
3.3.2	Backward Propagation and Motion Compensation	14
3.3.3	Residual computation	15
3.3.4	Iterated state update	15
3.3.5	The algorithm	19
3.4	Map Update	20
3.5	Initialization	20

4	EXPERIMENT RESULTS	20
4.1	Computational Complexity Experiments	20
4.2	UAV Flight Experiments	20
4.3	Indoor Experiments	20
4.4	Outdoor Experiments	20

1 Abstract

- 高计算效率、高鲁棒性的雷达里程计
- 紧耦合迭代扩展卡尔曼滤波
- 新卡尔曼增益计算公式
- 1200 特征点 25ms

2 Introduction

- 视觉传感器对光照敏感、雷达（旋转式）体积大成本高，不适用于小型机器人
- 固态雷达低成本、重量轻
- 固态雷达带来的新挑战：
 - 1) 特征少的场景易退化，小 FOV 雷达更明显
 - 2) 数千个特征点 +IMU 数据导致计算量太大
 - 3) 激光点采样时间不同，运动失真
- 本文提出了：
 - 1) 迭代卡尔曼滤波融合雷达和 IMU 数据，反向传播来补偿运动失真
 - 2) 新卡尔曼增益计算公式，减少计算量
 - 3) 实验表明能在四旋翼机载计算机实时运行

3 Methodology

3.1 Framework Overview

- 雷达输入到预处理模块，经过一段时间的累积后进行特征提取，提取出面点和角点
- IMU 输入进行前向传播 (积分得到粗略位姿估计)，反向传播进行运动补偿
- 计算雷达里程计的残差，利用迭代卡尔曼滤波估计位姿变换，直到收敛。最后根据位姿建图，并更新特征地图。

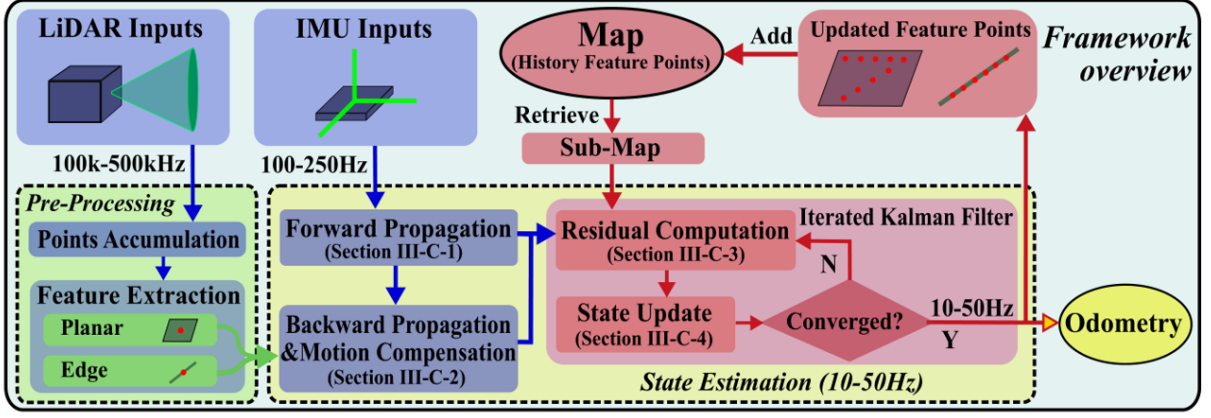


Figure 1: System overview.

3.2 System description

3.2.1 \boxplus / \boxminus operator

首先论文定义了一个新的运算符 \boxplus 和 \boxminus :

$$\begin{aligned} \boxplus : \mathcal{M} \times \mathbb{R}^n &\rightarrow \mathcal{M}; \quad \boxminus : \mathcal{M} \times \mathcal{M} \rightarrow \mathbb{R}^n \\ \mathcal{M} = SO(3) : \mathbf{R} \boxplus \mathbf{r} &= \mathbf{R} \text{Exp}(\mathbf{r}); \quad \mathbf{R}_1 \boxminus \mathbf{R}_2 = \log(\mathbf{R}_2^T \mathbf{R}_1) \\ \mathcal{M} = \mathbb{R}^n : \mathbf{a} \boxplus \mathbf{b} &= \mathbf{a} + \mathbf{b}; \quad \mathbf{a} \boxminus \mathbf{b} = \mathbf{a} - \mathbf{b} \end{aligned} \quad (1)$$

这里的 \mathcal{M} 表示一种 n 维的流形。 \times 表示运算, 例如 \mathcal{M} 上的一个元素和 \mathbb{R}^n 上的向量进行 \boxplus 运算, 结果还是 \mathcal{M} 上的元素, \boxminus 同理。下文将简单介绍流形相关的知识。当然, 读者也可以完全不用了解流形相关的知识, 只是把它当作是一种简化的方式, 或者类似 C++ 的运算符重载即可。这不会影响后续对于论文的理解。

首先我们讨论一下什么是流形 (Manifold)。流形官方的定义是: **局部具有欧几里得空间性质的空间**, 在数学中用于描述几何形体。然而, 读者看到这句话可能并不清楚流形到底是什么, 因此我们首先介绍两个示例。我们要表示一个空间, 这个空间的所有点都在单位圆上。读者很自然的想到用直角坐标系来表达它, 例如 (1,0) 和 (0,1) 都属于这个空间。但是这种表达方式是冗余的, 因为直角坐标系的大部分点都不在单位圆上。我们希望能建立某一种描述方法, 让这个描述方法所确定的所有点的集合都能在圆上, 甚至能连续不间断地表示圆上的点。这种方式就是极坐标。在原点的圆只需要给定一个半径 R , 就能产生连续不断的圆上的点。因此, 二维空间中的圆是一个一维流形。另一个例子是三维空间的球面。如果用 (x,y,z) 三维坐标来表述这个空间会产生冗余, 因此我们可以用经纬度或球面极坐标来表述它, 因此, 三维空间中的球面是一个二维流形。如图 2 所示。

流形学的观点是认为: **我们所能观察到的数据实际上是由一个低维流形映射到高维空**

间上的，即这些数据所在的空间是“嵌入在高维空间的低维流形”。由于数据内部特征的限制，一些高维中的数据会产生维度上的冗余，实际上只需要比较低的维度就能唯一地表示。注意，**流形**是一个“空间”，而不是一个“形状”。(以上关于流形的理解参考[2])

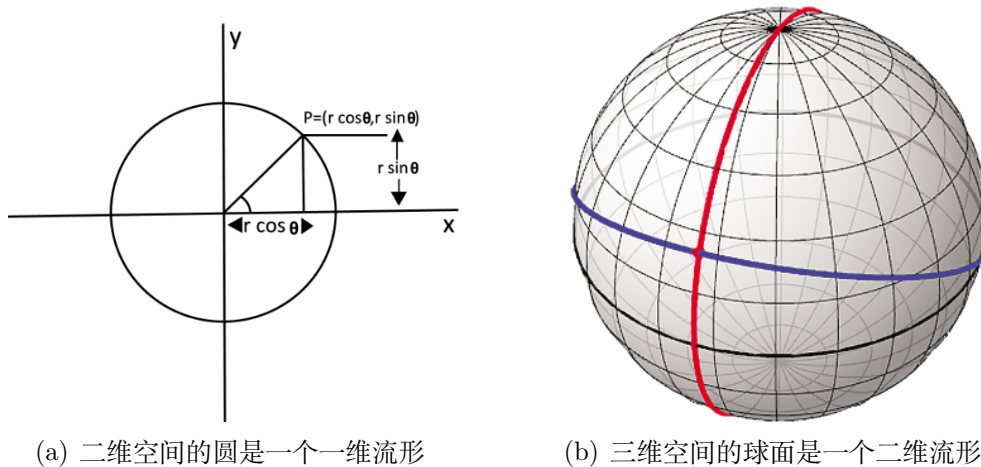


Figure 2: 流形的示例

在论文中我们经常会看到局部同胚 (locally homeomorphic) 这个词。一种非正式但便于理解的描述如下。设流形为 \mathcal{M} , 对于 $\forall x \in \mathcal{M}$ 和一个包含 x 的开子集 $U \subset \mathcal{M}$, 存在一个双射函数 (又叫同胚) ϕ , 它可以把 U 中的点映射到 \mathbb{R}^n 上的一个开子集。如图 3 所示。




Figure 3: 运算符 田 的说明 [3]。 \mathbb{R}^n 空间在点 x 处局部同胚于 \mathcal{M} 。

其中 \mathcal{M}_{ϕ_x} 是点 x 附近的同胚 (双射函数)。在 [3] 中，广义的 田 和 日 是这样定义的：

$$\begin{aligned}
 \text{田} : \mathcal{M} \times \mathbb{R}^n &\rightarrow \mathcal{M} & \mathbf{x} \text{ 田}_{\mathcal{M}} \mathbf{u} &= \mathcal{M}_{\phi_x^{-1}}(\mathbf{u}) \\
 \text{日} : \mathcal{M} \times \mathcal{M} &\rightarrow \mathbb{R}^n & \mathbf{y} \text{ 日}_{\mathcal{M}} \mathbf{x} &= \mathcal{M}_{\phi_x}(\mathbf{y})
 \end{aligned} \tag{2}$$

其中 $\forall \mathbf{x}, \mathbf{y} \in \mathcal{M}, \mathbf{u} \in \mathbb{R}^n$ 。田的物理含义可以理解为在 $x \in \mathcal{M}$ 处添加一个小的扰动 $u \in \mathbb{R}^n$ ，逆运算 \boxminus 则是确定扰动 u 。这看起来可能还是有些抽象，但当 \mathcal{M} 是李群时就比较清楚 (例如 $\mathcal{M} = SO(3)$)，此时 \boxplus, \boxminus 定义为：

$$\mathbf{x} \boxplus_{\mathcal{M}} \mathbf{u} = \mathbf{x} \cdot \text{Exp}(\mathbf{u}); \quad \mathbf{y} \boxminus_{\mathcal{M}} \mathbf{x} = \log(\mathbf{x}^{-1} \cdot \mathbf{y}) \quad (3)$$

也就是说，此时 $\mathcal{M}_{\varphi_{\mathbf{x}}}$ 是对数映射， $\mathcal{M}_{\varphi_{\mathbf{x}}^{-1}}$ 是指数映射。 $\mathbf{x} \boxplus_{\mathcal{M}} \mathbf{u}$ 可以理解为 x 乘上扰动 u 的指数映射，相当于在矩阵 x 上添加了一个李代数上的扰动 u ，而 $\mathbf{y} \boxminus_{\mathcal{M}} \mathbf{x}$ 是求李代数上的扰动。至此的知识已经足够我们理解相关论文中关于流形的描述。其他关于流形的知识请读者自行查阅。

回到论文中，定义复合流形的运算：

$$\begin{bmatrix} \mathbf{R} \\ \mathbf{a} \end{bmatrix} \boxplus \begin{bmatrix} \mathbf{r} \\ \mathbf{b} \end{bmatrix} = \begin{bmatrix} \mathbf{R} \boxplus \mathbf{r} \\ \mathbf{a} + \mathbf{b} \end{bmatrix}; \quad \begin{bmatrix} \mathbf{R}_1 \\ \mathbf{a} \end{bmatrix} \boxminus \begin{bmatrix} \mathbf{R}_2 \\ \mathbf{b} \end{bmatrix} = \begin{bmatrix} \mathbf{R}_1 \boxminus \mathbf{R}_2 \\ \mathbf{a} - \mathbf{b} \end{bmatrix} \quad (4)$$

以及以下易于验证的结论：

$$(\mathbf{x} \boxplus \mathbf{u}) \boxminus \mathbf{x} = \mathbf{u}; \quad \mathbf{x} \boxplus (\mathbf{y} \boxminus \mathbf{x}) = \mathbf{y}; \quad \forall \mathbf{x}, \mathbf{y} \in \mathcal{M}, \forall \mathbf{u} \in \mathbb{R}^n. \quad (5)$$

3.2.2 Continuous model

这一节主要讲的是 IMU 的运动模型及其积分。IMU 坐标系记为 I ，雷达坐标系记为 L ，IMU 和雷达之间的外参定义为 ${}^I\mathbf{T}_L = ({}^I\mathbf{R}_L, {}^I\mathbf{p}_L)$ 。IMU 的运动模型如下 (第一帧 IMU 的坐标系，定义为全局坐标系 G)：

$$\begin{aligned} {}^G\dot{\mathbf{p}}_I &= {}^G\mathbf{v}_I, {}^G\dot{\mathbf{v}}_I = {}^G\mathbf{R}_I(\mathbf{a}_m - \mathbf{b}_a - \mathbf{n}_a) + {}^G\mathbf{g}, {}^G\dot{\mathbf{g}} = \mathbf{0} \\ {}^G\dot{\mathbf{R}}_I &= {}^G\mathbf{R}_I[\boldsymbol{\omega}_m - \mathbf{b}_\omega - \mathbf{n}_\omega]_{\wedge}, \dot{\mathbf{b}}_\omega = \mathbf{n}_{b\omega}, \dot{\mathbf{b}}_a = \mathbf{n}_{ba} \end{aligned} \quad (6)$$

我们先来看其中比较好理解的几个。 ${}^G\mathbf{g}$ 是重力矢量，我们认为它是不随时间变化的，因此它的导数为 0。 \mathbf{n}_a 和 \mathbf{n}_ω 是 IMU 测量值的白噪声。 \mathbf{b}_a 和 \mathbf{b}_ω 分别是 IMU 的零偏，我们认为它符合随机游走模型，即它们的导数服从高斯分布。要理解其他几个量，首先我们要知道 IMU 的测量值和真值的关系：

$$\begin{aligned} \mathbf{a}_m &= \mathbf{a} + \mathbf{b}_a + \mathbf{n}_a - {}^I\mathbf{R}_G {}^G\mathbf{g} \\ \boldsymbol{\omega}_m &= \boldsymbol{\omega} + \mathbf{b}_\omega + \mathbf{n}_\omega \end{aligned} \quad (7)$$

其中 $\mathbf{a}, \boldsymbol{\omega}$ 表示加速度和角速度真值。这个式子是通用的 IMU 的测量模型，它是易于

理解的, 即测量值 = 真值 + 零偏 + 噪声。需要注意的是加速度测量值多包含了一项重力分量, 由于它是不随时间变化的, 因此只需要把第一帧 (Global 坐标系) 的重力分量乘上变换矩阵 ${}^I\mathbf{R}_G$ 转换到当前 IMU 的坐标系即可 (这里令成减去 ${}^I\mathbf{R}_G^G\mathbf{g}$ 是为了与论文公式统一, 实际代码中可根据 IMU 重力加速度的正负号来决定是加还是减号)。

接下来回到公式 (6)。 ${}^G\mathbf{p}_I, {}^G\mathbf{v}_I$ 和 ${}^G\mathbf{R}_I$ 分别是全局坐标系的位置, 速度和姿态。其中位置的导数是速度, 速度的导数是加速度 (式中转换到 G 坐标系), 这是易于理解的。关于 ${}^G\mathbf{R}_I$ 的导数的推导如下, 其中主要参考了 [4]。

考虑考虑一个从原点出发的向量 \mathbf{r} 绕单位轴 \mathbf{u} 旋转, 角速度大小为 $\dot{\theta}$, 角速度可表示为 $\boldsymbol{\omega} = \dot{\theta}\mathbf{u}$, 如图 4所示。则 \mathbf{r} 的导数为:

$$\frac{d\mathbf{r}}{dt} = \boldsymbol{\omega} \times \mathbf{r} \quad (8)$$




Figure 4: IMU 运动模型推导.

现在考虑图 (右), 坐标系 B 绕单位轴 \mathbf{u} 旋转, 其三个单位轴的时间一阶导为:

$$\frac{d\mathbf{i}_B}{dt} = \boldsymbol{\omega} \times \mathbf{i}_B, \frac{d\mathbf{j}_B}{dt} = \boldsymbol{\omega} \times \mathbf{j}_B, \frac{d\mathbf{k}_B}{dt} = \boldsymbol{\omega} \times \mathbf{k}_B \quad (9)$$

实际上, $[\mathbf{i}_B, \mathbf{j}_B, \mathbf{k}_B]$ 是一组单位正交基, 它和原坐标系的基的内积就是旋转矩阵 (这一部分可以参考十四讲第 3 讲)。而原坐标系的基就是单位阵, 因此, $[\mathbf{i}_B, \mathbf{j}_B, \mathbf{k}_B]$ 实际上就是坐标系 B 相对于原坐标系的旋转矩阵 \mathbf{R} , 因此有:

$$\dot{\mathbf{R}} = \begin{bmatrix} \boldsymbol{\omega} \times \mathbf{i}_B & \boldsymbol{\omega} \times \mathbf{j}_B & \boldsymbol{\omega} \times \mathbf{k}_B \end{bmatrix} = \boldsymbol{\omega} \times \mathbf{R} = \boldsymbol{\omega}^\wedge \mathbf{R} \quad (10)$$

其中 $^\wedge$ 表示向量对应的反对称矩阵 (论文中同理)。然而这里的角速度 $\boldsymbol{\omega}$ 是原坐标系下的, 对应论文中的 Global 坐标系; 而图中变换后的坐标系对应论文中的 IMU 坐标系。已知 ${}^G\boldsymbol{\omega} = {}^G\mathbf{R}_I \cdot {}^I\boldsymbol{\omega}$, 以及对任意旋转矩阵 \mathbf{R} 和三维向量 \mathbf{p} , 都有 $(\mathbf{R}\mathbf{p})^\wedge = \mathbf{R}\mathbf{p}^\wedge\mathbf{R}^T$ (证明

见 [4]), 于是有:

$$\dot{\mathbf{G}}\mathbf{R}_I = (\mathbf{G}\mathbf{R}_I \cdot {}^I\boldsymbol{\omega})^\wedge \mathbf{G}\mathbf{R}_I = \mathbf{G}\mathbf{R}_I ({}^I\boldsymbol{\omega})^\wedge \quad (11)$$

这个式子和 (6) 是一致的。

3.2.3 Discrete model

这一节主要讲的是离散化上述的状态模型。通过前文求得的导数, 有如下离散模型:

$$\mathbf{x}_{i+1} = \mathbf{x}_i \boxplus (\Delta t \mathbf{f}(\mathbf{x}_i, \mathbf{u}_i, \mathbf{w}_i)) \quad (12)$$

这个公式其实就代表了文中提到的**前向传播 (Forward Propagation)**, 其中 i 是 IMU 测量的 index, 其他定义如下:

$$\begin{aligned} \mathcal{M} &= SO(3) \times \mathbb{R}^{15}, \dim(\mathcal{M}) = 18 \\ \mathbf{x} &\doteq \begin{bmatrix} {}^G\mathbf{R}_I^T & {}^G\mathbf{p}_I^T & {}^G\mathbf{v}_I^T & \mathbf{b}_\omega^T & \mathbf{b}_a^T & {}^G\mathbf{g}^T \end{bmatrix}^T \in \mathcal{M} \\ \mathbf{u} &\doteq \begin{bmatrix} \boldsymbol{\omega}_m^T & \mathbf{a}_m^T \end{bmatrix}^T, \mathbf{w} \doteq \begin{bmatrix} \mathbf{n}_\omega^T & \mathbf{n}_a^T & \mathbf{n}_{b\omega}^T & \mathbf{n}_{ba}^T \end{bmatrix}^T \\ \mathbf{f}(\mathbf{x}_i, \mathbf{u}_i, \mathbf{w}_i) &= \begin{bmatrix} \boldsymbol{\omega}_{m_i} - \mathbf{b}_{\omega_i} - \mathbf{n}_{\omega_i} \\ {}^G\mathbf{v}_{I_i} \\ \mathbf{R}_{I_i}(\mathbf{a}_{m_i} - \mathbf{b}_{a_i} - \mathbf{n}_{a_i}) + {}^G\mathbf{g}_i \\ \mathbf{n}_{b\omega_i} \\ \mathbf{n}_{ba} \\ \mathbf{0}_{3 \times 1} \end{bmatrix} \end{aligned} \quad (13)$$

这个公式是易于推导的, 读者可自行展开验证。可以看出我们要实时估计的是一个 18 维的量 x , 它包含位置, 姿态, 速度以及 IMU 的参数。因此它是一个紧耦合的框架。

3.2.4 Discrete model

这一节是雷达数据的预处理, 因为作者使用的是固态雷达, 因此对固态雷达数据的处理做了如下额外的说明:

- 原始点的采集频率很高 (200kHz), 因此通常累计一定时间 (20ms, 即 50Hz) 的点作为一次 scan
- 从原始点中提取平面点和边缘点 (LOAM), 设特征点的总数量为 m , 每个特征点的时间戳为 ρ_j , 并定义每个 IMU 帧的时间戳为 τ_i , 如图 5 所示

- 最后一个特征点是一次 scan 的终点，即 $\rho_m = t_k$ ，但 IMU 测量值不与起点或终点对齐




Figure 5: 前向和反向传播.

3.3 State Estimation

本节讲的利用误差卡尔曼滤波来估计状态量 x 。我们首先明确文中的定义：

- x 表示真值
- \bar{x} 表示滤波算法结束后得到的最优估计
- \hat{x} 表示滤波算法过程中得到的估计值
- \tilde{x} 表示误差

假设我们现在准备进行第 k 帧的状态估计，那么第 $k-1$ 帧的估计是已完成的。因此，我们定义误差量：

$$\tilde{\mathbf{x}}_{k-1} \doteq \mathbf{x}_{k-1} \boxminus \bar{\mathbf{x}}_{k-1} = \begin{bmatrix} \delta \boldsymbol{\theta}^T & {}^G \tilde{\mathbf{p}}_I^T & {}^G \tilde{\mathbf{v}}_I^T & \tilde{\mathbf{b}}_\omega^T & \tilde{\mathbf{b}}_a^T & {}^G \tilde{\mathbf{g}}^T \end{bmatrix}^T \quad (14)$$

这里由于第 $k-1$ 帧的估计是已完成的，因此该式中误差使用的是 $\bar{\mathbf{x}}_{k-1}$ 而不是像后文中使用 $\hat{\mathbf{x}}_{k-1}$ ，此处易混淆，请读者注意。其中 $\delta \boldsymbol{\theta} = \log \left({}^G \mathbf{R}_I^{TG} \mathbf{R}_I \right)$ 表示真实姿态和估计姿态之间的小偏差。其他项的误差是向量空间的，直接相减即可。此外，定义协方差矩阵为 $\bar{\mathbf{P}}_{k-1}$ 。

3.3.1 Forward Propagation

本节讲的是前向传播。前向传播实际上有 2 个内容：一个是**通过 IMU 积分计算一个粗略的状态量 \hat{x}_k** (见图 5)，这个状态量会用于后续的反向传播来补偿运动失真。公式如下：

$$\hat{\mathbf{x}}_{i+1} = \hat{\mathbf{x}}_i \oplus (\Delta t \mathbf{f}(\hat{\mathbf{x}}_i, \mathbf{u}_i, \mathbf{0})); \hat{\mathbf{x}}_0 = \bar{\mathbf{x}}_{k-1} \quad (15)$$

其中 $\Delta t = \tau_{i+1} - \tau_i$ ，表示相邻两帧 IMU 之间的时间差。这里的噪声量 $\mathbf{w}_i = 0$ 是因为我们并不知道噪声的实际大小，因此在传播过程中设为零（噪声实际上会在后续的误差状态方程中考虑）。这个公式和离散模型的公式是一致的。我们每接收一个 IMU 都会进行一次上述计算，直到计算到最后一个 IMU 帧为止。

另一个内容是**传播误差量，并计算对应的协方差矩阵**。这里读者可能会疑惑：我们不知道真值，怎么计算误差呢？实际上，我们计算的误差量，也是一个近似值，因此它才会有对应的协方差矩阵来评判置信度。和传统的卡尔曼滤波器不同的是，传统的卡尔曼滤波器直接估计状态量 x ，它的运动方程和观测方程通常长这样：

$$\begin{aligned} \mathbf{x}_k &= \mathbf{f}(\mathbf{x}_{k-1}, \mathbf{u}_k) + \mathbf{w}_k \\ \mathbf{z}_k &= \mathbf{h}(\mathbf{x}_k) + \mathbf{v}_k \end{aligned} \quad (16)$$

而文中使用的**误差状态卡尔曼滤波器 (Error state Kalman filter,ESKF)**，以误差量作为待估计量，也就是把上式的 x 用 \tilde{x} 代替：

$$\begin{aligned} \tilde{\mathbf{x}}_k &= \tilde{\mathbf{f}}(\tilde{\mathbf{x}}_{k-1}, \mathbf{u}_k) + \tilde{\mathbf{w}}_k \\ \mathbf{z}_k &= \tilde{\mathbf{h}}(\tilde{\mathbf{x}}_k) + \tilde{\mathbf{v}}_k \end{aligned} \quad (17)$$

上式中的 $\tilde{\mathbf{f}}, \tilde{\mathbf{h}}$ 等可能并不是一个严谨的表达，但读者应能明白它的含义。也就是说，我们现在要估计的是误差量 \tilde{x} ，而不是直接估计状态量 x 。而有了误差量的估计，再直接加上状态量的估计就是我们求得的最优估计 ($\tilde{\mathbf{x}}_{k-1} \oplus \mathbf{x}_{k-1} \oplus \bar{\mathbf{x}}_{k-1}$ ，公式 (14))。这将带来以下好处 [5]：

- 在旋转的处理上，ESKF 的状态变量可以采用最小化的参数表达，也就是使用三维变量来表达旋转的增量。而传统 KF 需要用到四元数 (4 维) 或者更高维的表达 (旋转矩阵, 9 维)，或采用带有奇异性的表达方式 (欧拉角)
- ESKF 总是在原点附近，离奇异点较远，并且也不会由于离工作点太远而导致线性化近似不够的问题
- ESKF 的状态量为小量，其二阶变量相对来说可以忽略。同时大多数雅可比矩阵

在小量情况下变得非常简单，甚至可以用单位阵代替

- 误差状态的运动学也相比原状态变量要来得更小，因为我们可以把大量更新部分放到原状态变量中

了解了 ESKF 的好处之后，我们现在要做的就是求公式 (17) 中的 \tilde{f}, \tilde{h} 的具体表达式，并且将它们线性化。回到论文中，对于运动方程，误差模型如下：

$$\begin{aligned}\tilde{\mathbf{x}}_{i+1} &= \mathbf{x}_{i+1} \ominus \hat{\mathbf{x}}_{i+1} \\ &= (\mathbf{x}_i \boxplus \Delta t \mathbf{f}(\mathbf{x}_i, \mathbf{u}_i, \mathbf{w}_i)) \ominus (\hat{\mathbf{x}}_i \boxplus \Delta t \mathbf{f}(\hat{\mathbf{x}}_i, \mathbf{u}_i, \mathbf{0})) \\ &\simeq \mathbf{F}_{\tilde{\mathbf{x}}} \tilde{\mathbf{x}}_i + \mathbf{F}_{\mathbf{w}} \mathbf{w}_i.\end{aligned}\tag{18}$$

这里的 $\mathbf{F}_{\tilde{\mathbf{x}}}$ 和 $\mathbf{F}_{\mathbf{w}}$ 是两个大的稀疏矩阵，具体形式见论文。这两个麻烦的家伙我们稍后再推导它。假设白噪声 \mathbf{w} 的协方差矩阵为 \mathbf{Q} ，则可以按照下式传播协方差矩阵：

$$\hat{\mathbf{P}}_{i+1} = \mathbf{F}_{\tilde{\mathbf{x}}} \hat{\mathbf{P}}_i \mathbf{F}_{\tilde{\mathbf{x}}}^T + \mathbf{F}_{\mathbf{w}} \mathbf{Q} \mathbf{F}_{\mathbf{w}}^T; \hat{\mathbf{P}}_0 = \bar{\mathbf{P}}_{k-1}\tag{19}$$

这个公式推导自高斯分布运算的基本性质。至此我们完成了前向传播的 2 个内容，即求得了状态估计 $\hat{\mathbf{x}}_k$ ，又推导了误差状态的传播，并求得了真实状态和估计状态之间误差的协方差 $\hat{\mathbf{P}}_k$ 。

接下来我们来推导式 (18)。实际上 ESKF 的误差状态传播有两种推导方式。一种是类似 [5] 中的方法，即基于误差随时间变化的递推方程。如果我们能够推导状态误差随时间变化的导数关系，例如 $\dot{\delta \mathbf{x}} = \mathbf{A} \delta \mathbf{x} + \mathbf{B} \mathbf{w}$ 。则误差状态的传递方程为：

$$\delta \mathbf{x}_k = \delta \mathbf{x}_{k-1} + \dot{\delta \mathbf{x}}_{k-1} \Delta t\tag{20}$$

这种推导方式可以得到和文中类似的结论（矩阵内有些项可能与 FAST-LIO 不同，其实是简化成了单位阵）。关于这种推导方式可以参考 [5][6]。而我们着重介绍的是论文中使用的基于一节泰勒展开的误差传递方法。非线性系统 $\mathbf{x}_k = f(\mathbf{x}_{k-1}, \mathbf{u}_{k-1})$ 的状态误差的线性递推关系如下：

$$\begin{aligned}\mathbf{x}_k &= f(\mathbf{x}_{k-1}, \mathbf{u}_{k-1}, \mathbf{w}_{k-1}) \\ &\rightarrow \hat{\mathbf{x}}_k + \delta \mathbf{x}_k = f(\hat{\mathbf{x}}_{k-1} + \delta \mathbf{x}_{k-1}, \mathbf{u}_{k-1}, \mathbf{w}_{k-1}) \\ &\xrightarrow{Taylor} \hat{\mathbf{x}}_k + \delta \mathbf{x}_k = \underline{f(\hat{\mathbf{x}}_{k-1}, \mathbf{u}_{k-1}, 0)} + \mathbf{F} \delta \mathbf{x}_{k-1} + \mathbf{G} \mathbf{w}_{k-1} \\ &\rightarrow \delta \mathbf{x}_k = \mathbf{F} \delta \mathbf{x}_{k-1} + \mathbf{G} \mathbf{w}_{k-1}\end{aligned}\tag{21}$$

其中, \mathbf{F} 是状态量 \mathbf{x}_k 对状态量 \mathbf{x}_{k-1} 的雅可比矩阵, \mathbf{G} 是状态量 \mathbf{x}_k 对噪声量 \mathbf{w}_{k-1} 的雅可比矩阵。接下来我们的任务就是推导这两个矩阵。

回到论文中, 论文中的 $\mathbf{F}_{\tilde{\mathbf{x}}}$ 对应上式的 \mathbf{F} , $\mathbf{F}_{\mathbf{w}}$ 对应上式的 \mathbf{G} 。我们已知:

- 由公式 (18): $\tilde{\mathbf{x}}_{i+1} = \mathbf{x}_{i+1} \boxminus \hat{\mathbf{x}}_{i+1} = (\mathbf{x}_i \boxplus \Delta t \mathbf{f}(\mathbf{x}_i, \mathbf{u}_i, \mathbf{w}_i)) \boxminus (\hat{\mathbf{x}}_i \boxplus \Delta t \mathbf{f}(\hat{\mathbf{x}}_i, \mathbf{u}_i, \mathbf{0}))$
- $\mathbf{x}_i = \hat{\mathbf{x}}_i \boxplus \tilde{\mathbf{x}}_i$
- 定义 $\mathbf{g}(\tilde{\mathbf{x}}_i, \mathbf{w}_i) = \mathbf{f}(\mathbf{x}_i, \mathbf{u}_i, \mathbf{w}_i) \Delta t = \mathbf{f}(\hat{\mathbf{x}}_i \boxplus \tilde{\mathbf{x}}_i, \mathbf{u}_i, \mathbf{w}_i) \Delta t$

则公式 (18) 可以写为:

$$\tilde{\mathbf{x}}_{i+1} = ((\hat{\mathbf{x}}_i \boxplus \tilde{\mathbf{x}}_i) \boxplus \mathbf{g}(\tilde{\mathbf{x}}_i, \mathbf{w}_i)) \boxminus (\hat{\mathbf{x}}_i \boxplus \mathbf{g}(\mathbf{0}, \mathbf{0})) \stackrel{def}{=} \mathbf{G}(\tilde{\mathbf{x}}_i, \mathbf{g}(\tilde{\mathbf{x}}_i, \mathbf{w}_i)) \quad (22)$$

以上内容见原文附录。为了简化, 在后续推导中我们省去上式中烦人的下标 i 。我们要求的是 $\mathbf{G}(\tilde{\mathbf{x}}, \mathbf{g}(\tilde{\mathbf{x}}, \mathbf{w}))$ 对 $\tilde{\mathbf{x}}$ 和 \mathbf{w} 的偏导 (在 $\tilde{x} = w = 0$ 附近, 因为 \tilde{x} 是误差量接近 0, w 是噪声)。这是一个复合函数, 因此有:

$$F_{\tilde{x}} = \frac{\partial G(\tilde{x}, g(0, 0))}{\partial \tilde{x}} + \frac{\partial G(0, g(\tilde{x}, 0))}{\partial g(\tilde{x}, 0)} \frac{\partial g(\tilde{x}, 0)}{\partial \tilde{x}} \Big|_{\tilde{x}=0} \stackrel{simplify}{=} \frac{\partial G}{\partial \tilde{x}} + \frac{\partial G}{\partial g} \frac{\partial g}{\partial \tilde{x}} \Big|_{\tilde{x}=0} \quad (23)$$

$$F_w = \frac{\partial G(0, g(0, w))}{\partial g(0, w)} \frac{\partial g(0, w)}{\partial w} \Big|_{w=0} \stackrel{simplify}{=} \frac{\partial G}{\partial g_w} \frac{\partial g}{\partial w} \Big|_{w=0} \quad (24)$$

接下来, 我们先考虑这样一个流形的偏导数。对于流形 $\mathbf{E} = ((\mathbf{a} \boxplus \mathbf{b}) \boxplus \mathbf{c}) \boxminus \mathbf{d}$, 有以下结论 [3]:

$$\frac{\partial \mathbf{E}}{\partial \mathbf{b}} = \frac{\partial \mathbf{E}}{\partial \mathbf{c}} = \mathbf{I}_{n \times n}, \quad a, b, c, d \in \mathbb{R}^n \quad (25)$$

$$\frac{\partial \mathbf{E}}{\partial \mathbf{b}} = \mathbf{A}(\mathbf{E})^{-T} \mathbf{E} \mathbf{xp}(-\mathbf{c}) \mathbf{A}(\mathbf{b})^T, \quad \frac{\partial \mathbf{E}}{\partial \mathbf{c}} = \mathbf{A}(\mathbf{E})^{-T} \mathbf{A}(\mathbf{c})^T, \quad a, d \in SO(3), b, c \in \mathbb{R}^3 \quad (26)$$

其中

$$\mathbf{A}(\mathbf{u})^{-1} = \mathbf{I} - \frac{1}{2} [\mathbf{u}]_{\wedge} + (1 - \alpha(\|\mathbf{u}\|)) \frac{[\mathbf{u}]_{\wedge}^2}{\|\mathbf{u}\|^2} \quad (27)$$

$$\alpha(m) = \frac{m}{2} \cot\left(\frac{m}{2}\right) = \frac{m \cos(m/2)}{2 \sin(m/2)}$$

也就是 BCH 近似中的雅可比矩阵 (见 14 讲)。对于式 (25), 这是显然的, 因为欧式空

间下 \boxplus 就是常用的加减法。我们接下来推导式 (26)。关于 \mathbf{b} 求偏导如下：

$$\begin{aligned}
E &= ((a \boxplus b) \boxplus c) \boxminus d = \text{Log}(d^{-1} \cdot (a \boxplus b) \boxplus c) \\
&\rightarrow \text{Exp}(E) = d^{-1} \cdot a \cdot \text{Exp}(b) \cdot \text{Exp}(c) \\
&\rightarrow \text{Exp}(E + \Delta E) = d^{-1} \cdot a \cdot \text{Exp}(b + \Delta b) \cdot \text{Exp}(c) \\
&\xrightarrow{BCH} \text{Exp}(E) \text{Exp}(A(E)^T \Delta E) = d^{-1} \cdot a \cdot \text{Exp}(b) \text{Exp}(A(b)^T \Delta b) \cdot \text{Exp}(c) \\
&\rightarrow \text{Exp}(A(E)^T \Delta E) = \text{Exp}(-c) \text{Exp}(A(b)^T \Delta b) \cdot \text{Exp}(c) \\
&\rightarrow \text{Exp}(A(E)^T \Delta E) \xrightarrow{\text{Property}} \text{Exp}(\text{Exp}(-c) A(b)^T \Delta b) \\
&\rightarrow \frac{\Delta E}{\Delta b} = A(E)^{-T} \text{Exp}(-c) A(b)^T
\end{aligned} \tag{28}$$

其中第四行用了 BCH 近似公式，倒数第二行用了 $\text{SO}(3)$ 上矩阵的伴随性质。关于 \mathbf{c} 求偏导同理：

$$\begin{aligned}
&\rightarrow \text{Exp}(E + \Delta E) = d^{-1} \cdot a \cdot \text{Exp}(b) \cdot \text{Exp}(c + \Delta c) \\
&\xrightarrow{BCH} \text{Exp}(E) \text{Exp}(A(E)^T \Delta E) = d^{-1} \cdot a \cdot \text{Exp}(b) \cdot \text{Exp}(c) \text{Exp}(A(c)^T \Delta c) \\
&\rightarrow \text{Exp}(A(E)^T \Delta E) = \text{Exp}(A(c)^T \Delta c) \\
&\rightarrow \frac{\Delta E}{\Delta c} = A(E)^{-T} A(c)^T
\end{aligned} \tag{29}$$

至此我们完成了式 (26) 的推导。回到式 (23)(24)，实际上 \mathbf{G} 就是形如 $((\mathbf{a} \boxplus \mathbf{b}) \boxplus \mathbf{c}) \boxminus \mathbf{d}$ 的形式，因为 $\mathbf{G} = (\hat{\mathbf{x}} \boxplus \tilde{\mathbf{x}}) \boxplus \mathbf{g}(\tilde{\mathbf{x}}, \mathbf{w}) \boxminus (\hat{\mathbf{x}} \boxplus \mathbf{g}(\mathbf{0}, \mathbf{0}))$ 。由 $F_{\tilde{x}} = \frac{\partial G}{\partial \tilde{x}} + \frac{\partial G}{\partial \mathbf{g}} \frac{\partial \mathbf{g}}{\partial \tilde{x}} \Big|_{\tilde{x}=\mathbf{0}}$ ，我们推导：

$$\begin{aligned}
\frac{\partial G}{\partial \tilde{x}} \Big|_{\tilde{x}=\mathbf{0}} &\xrightarrow{(26)} \begin{bmatrix} \mathbf{A}(\mathbf{0})^{-1} \mathbf{Exp}(-\mathbf{g}(\mathbf{0}, \mathbf{0})) \mathbf{A}(\mathbf{0})^T & 0 \\ 0 & \mathbf{I}_{15 \times 15} \end{bmatrix} \\
&= \begin{bmatrix} \mathbf{Exp}(-\mathbf{f}(\hat{\mathbf{x}}, \mathbf{u}, \mathbf{0}) \Delta \mathbf{t}) & 0 \\ 0 & \mathbf{I}_{15 \times 15} \end{bmatrix} \\
&= \begin{bmatrix} \mathbf{Exp}(-(\omega_{\mathbf{m}} - \hat{\mathbf{b}}_{\omega}) \Delta \mathbf{t}) & 0 \\ 0 & \mathbf{I}_{15 \times 15} \end{bmatrix}
\end{aligned} \tag{30}$$

其中，当 $\tilde{x} = 0$ 时， $G = 0$ 且 $A(0) = I$ (易于验证)。由于状态量 x 第一项是 $\text{SO}(3)$ 的，其它项都是向量，因此式中的矩阵只有前三行代入式 (26)，其他行代入式 (25)。同

理，我们推导：

$$\begin{aligned} \left. \frac{\partial G}{\partial g} \right|_{\tilde{x}=0} &\stackrel{(26)}{=} \begin{bmatrix} \mathbf{A}(\mathbf{0})^{-1} \mathbf{A}(\mathbf{g}(\mathbf{0}, \mathbf{0}))^T & 0 \\ 0 & \mathbf{I}_{15 \times 15} \end{bmatrix} \\ &= \begin{bmatrix} \mathbf{A}((\omega_m - \hat{\mathbf{b}}_\omega) \Delta t) & 0 \\ 0 & \mathbf{I}_{15 \times 15} \end{bmatrix} \end{aligned} \quad (31)$$

最后，关于 $\frac{\partial g}{\partial \tilde{x}}$ 的求解，由于 $\tilde{\mathbf{x}} \doteq \mathbf{x} \boxminus \hat{\mathbf{x}} = \begin{bmatrix} \delta \boldsymbol{\theta}^T & {}^G \tilde{\mathbf{p}}_I^T & {}^G \tilde{\mathbf{v}}_I^T & \tilde{\mathbf{b}}_\omega^T & \tilde{\mathbf{b}}_a^T & {}^G \tilde{\mathbf{g}}^T \end{bmatrix}^T$, $\mathbf{w} \doteq \begin{bmatrix} \mathbf{n}_\omega^T & \mathbf{n}_a^T & \mathbf{n}_{b\omega}^T & \mathbf{n}_{ba}^T \end{bmatrix}^T$ ，以及：

$$\begin{aligned} \mathbf{g}(\tilde{\mathbf{x}}, \mathbf{w}) &= \mathbf{f}(\mathbf{x}, \mathbf{u}, \mathbf{w}) \Delta t = \begin{bmatrix} \omega_m - \mathbf{b}_\omega - \mathbf{n}_\omega \\ {}^G \mathbf{v}_I \\ \mathbf{R}_I (\mathbf{a}_m - \mathbf{b}_a - \mathbf{n}_a) + {}^G \mathbf{g} \\ \mathbf{n}_{b\omega} \\ \mathbf{n}_{ba} \\ \mathbf{0}_{3 \times 1} \end{bmatrix} \Delta t \\ &= \begin{bmatrix} \omega_m - \hat{\mathbf{b}}_\omega - \tilde{\mathbf{b}}_\omega - \mathbf{n}_\omega \\ {}^G \hat{\mathbf{v}}_I + {}^G \tilde{\mathbf{v}}_I \\ \hat{\mathbf{R}}_I \text{Exp}(\delta \boldsymbol{\theta}^T) (\mathbf{a}_m - \hat{\mathbf{b}}_a - \tilde{\mathbf{b}}_a - \mathbf{n}_a) + {}^G \mathbf{g} \\ \mathbf{n}_{b\omega} \\ \mathbf{n}_{ba} \\ \mathbf{0}_{3 \times 1} \end{bmatrix} \Delta t \end{aligned} \quad (32)$$

则：

$$\left. \frac{\partial g(\tilde{\mathbf{x}}, 0)}{\partial \tilde{x}} \right|_{\tilde{x}=0} = \begin{pmatrix} 0 & 0 & 0 & -\mathbf{I}_{3 \times 3} \Delta t & 0 & 0 \\ 0 & 0 & \mathbf{I}_{3 \times 3} \Delta t & 0 & 0 & 0 \\ -\hat{\mathbf{R}}_I (\mathbf{a}_m - \hat{\mathbf{b}}_a)^\wedge \Delta t & 0 & 0 & 0 & -\hat{\mathbf{R}}_I \Delta t & \mathbf{I}_{3 \times 3} \Delta t \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} \quad (33)$$

其中，第三行关于 R 的求导利用了右乘扰动模型。至此，根据式 (23) 中： $F_{\tilde{x}} = \frac{\partial G}{\partial \tilde{x}} + \frac{\partial G}{\partial g} \frac{\partial g}{\partial \tilde{x}} \Big|_{\tilde{x}=0}$ ，

再加上不烦人的下标 i , 得到:

$$\mathbf{F}_{\tilde{\mathbf{x}}} = \begin{bmatrix} \mathbf{Exp}(-(\omega_{\mathbf{m}} - \hat{\mathbf{b}}_{\omega})\Delta t) & 0 & 0 & -\mathbf{A}((\omega_{\mathbf{m}} - \hat{\mathbf{b}}_{\omega})\Delta t)\Delta t & 0 & 0 \\ 0 & \mathbf{I} & \mathbf{I}\Delta t & 0 & 0 & 0 \\ -{}^G\widehat{\mathbf{R}}_{L_i}(\mathbf{a}_{\mathbf{m}} - \hat{\mathbf{b}}_{\mathbf{a}})^{\wedge}\Delta t & 0 & \mathbf{I} & 0 & -{}^G\widehat{\mathbf{R}}_{L_i}\Delta t & \mathbf{I}\Delta t \\ 0 & 0 & 0 & \mathbf{I} & 0 & 0 \\ 0 & 0 & 0 & 0 & \mathbf{I} & 0 \\ 0 & 0 & 0 & 0 & 0 & \mathbf{I} \end{bmatrix} \quad (34)$$

这和论文中是一致的结论 (注意论文中 $\hat{\omega}_i = \omega_{m_i} - \hat{\mathbf{b}}_{\omega_i}$, $\hat{\mathbf{a}}_i = \mathbf{a}_{m_i} - \hat{\mathbf{b}}_{\mathbf{a}_i}$)。

同理, 根据 $F_w = \left. \frac{\partial G}{\partial g_w} \frac{\partial g}{\partial w} \right|_{w=0}$, 我们推导:

$$\begin{aligned} \left. \frac{\partial G}{\partial g_w} \right|_{w=0} & \stackrel{(26)}{=} \begin{bmatrix} \mathbf{A}(\mathbf{0})^{-1} \mathbf{A}(\mathbf{g}(\mathbf{0}, \mathbf{0}))^{\mathbf{T}} & 0 \\ 0 & \mathbf{I}_{15 \times 15} \end{bmatrix} \\ & = \begin{bmatrix} \mathbf{A}((\omega_{\mathbf{m}} - \hat{\mathbf{b}}_{\omega})\Delta t) & 0 \\ 0 & \mathbf{I}_{15 \times 15} \end{bmatrix} \end{aligned} \quad (35)$$

以及:

$$\left. \frac{\partial g}{\partial w} \right|_{w=0} = \begin{pmatrix} -\mathbf{I}_{3 \times 3} \Delta t & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & -\hat{\mathbf{R}}_{\mathbf{I}} \Delta t & 0 & 0 \\ 0 & 0 & \mathbf{I}_{3 \times 3} & 0 \\ 0 & 0 & 0 & \mathbf{I}_{3 \times 3} \\ 0 & 0 & 0 & 0 \end{pmatrix} \quad (36)$$

加上下标 i , 得到:

$$F_w = \begin{pmatrix} -\mathbf{A}((\omega_{\mathbf{m}} - \hat{\mathbf{b}}_{\omega})\Delta t)\Delta t & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & -\hat{\mathbf{R}}_{\mathbf{I}} \Delta t & 0 & 0 \\ 0 & 0 & \mathbf{I} \Delta t & 0 \\ 0 & 0 & 0 & \mathbf{I} \Delta t \\ 0 & 0 & 0 & 0 \end{pmatrix} \quad (37)$$

至此, 我们终于推导完成这个大家伙了! 有了这个递推关系, 我们相当于已经完成了 ESKF 的运动方程的线性化的推导。后文我们将进行 ESKF 观测方程的推导。这里值得

一提的是，有部分读者可能会问，这与其它论文的结果或代码中的矩阵不太一样呢？实际上式中的部分量是可以简化的，例如 $-\mathbf{A}((\omega_{\mathbf{m}} - \hat{\mathbf{b}}_{\omega})\Delta t)\Delta t$ 可以简化为 \mathbf{I} ，因为 Δt 足够小。例如，简化后与 [5] 中的矩阵是一致的。

3.3.2 Backward Propagation and Motion Compensation

这一部分我们主要进行反向传播，即运动补偿。前文我们已经提到，由于雷达每个点的采样时间不同，而雷达在运动，会导致运动失真。我们希望拿到的数据是所有点在同一时刻的采样，文中是在 t_k 时刻。因此，我们根据 IMU 积分估计的位姿，把每个点转到 t_k 时刻，如图 6 所示。




Figure 6: 前向和反向传播.

从 $\hat{\mathbf{x}}_k$ 开始 (此处设为零点，因为我们实际上计算的是相对于 $\hat{\mathbf{x}}_k$ 的位姿)，利用 $\check{\mathbf{x}}_{j-1} = \check{\mathbf{x}}_j \boxminus (-\Delta \mathbf{tf}(\check{\mathbf{x}}_j, \mathbf{u}_j, \mathbf{0}))$ 计算相对位姿。通常点的频率是大于 IMU 频率的，因此对于两帧 IMU 之间的多个特征点，我们以左 IMU 帧为准。此外，考虑到 (13) 中后三行 (加速度噪声) 为零，我们把反向传播简化：

$$\begin{aligned}
 {}^{I_k}\check{\mathbf{p}}_{I_{j-1}} &= {}^{I_k}\check{\mathbf{p}}_{I_j} - {}^{I_k}\check{\mathbf{v}}_{I_j}\Delta t, \quad \text{s.f. } {}^{I_k}\check{\mathbf{p}}_{I_m} = \mathbf{0}; \\
 {}^{I_k}\check{\mathbf{v}}_{I_{j-1}} &= {}^{I_k}\check{\mathbf{v}}_{I_j} - {}^{I_k}\check{\mathbf{R}}_{I_j} \left(\mathbf{a}_{m_{i-1}} - \hat{\mathbf{b}}_{\mathbf{a}_k} \right) \Delta t - {}^{I_k}\hat{\mathbf{g}}_k \Delta t \\
 \text{s.f. } {}^{I_k}\check{\mathbf{v}}_{I_m} &= {}^G\hat{\mathbf{R}}_{I_k}^T {}^G\hat{\mathbf{v}}_{I_k} {}^{I_k}\hat{\mathbf{g}}_k = {}^G\hat{\mathbf{R}}_{I_k}^T \hat{\mathbf{g}}_k; \\
 {}^{I_k}\check{\mathbf{R}}_{I_{j-1}} &= {}^{I_k}\check{\mathbf{R}}_{I_j} \text{Exp} \left(\left(\hat{\mathbf{b}}_{\omega_k} - \omega_{m_{i-1}} \right) \Delta t \right), \quad \text{s.f. } {}^{I_k}\mathbf{R}_{I_m} = \mathbf{I}.
 \end{aligned} \tag{38}$$

其中 s.f. 表示”starting from”。定义我们反向传播得到的点的相对位姿是 ${}^{I_k}\check{\mathbf{T}}_{I_j} = \left({}^{I_k}\check{\mathbf{R}}_{I_j}, {}^{I_k}\check{\mathbf{p}}_{I_j} \right)$ ，我们把该点 ${}^{L_j}\mathbf{p}_{f_j}$ 投影到扫描结束时间 t_k ：

$${}^{L_k}\mathbf{p}_{f_j} = {}^{I_k}\mathbf{T}_L^{-1} {}^{I_k}\check{\mathbf{T}}_{I_j} {}^{I_k}\mathbf{T}_L {}^{L_j}\mathbf{p}_{f_j}. \tag{39}$$

其中 ${}^I\mathbf{T}_L$ 表示雷达坐标系转到 IMU 坐标系的外参矩阵，上式的含义是先把 L 坐标系的特征点转到 I 坐标系，然后乘上反向传播的补偿矩阵，再转回 L 坐标系。所有的投影点都像这样转好后，就可以开始计算残差了。

3.3.3 Residual computation

设迭代卡尔曼滤波的当前迭代为 κ (用于表示迭代的代数)，我们可以把补偿后的特征点转换到全局坐标系：

$${}^G\hat{\mathbf{p}}_{f_j}^\kappa = {}^G\hat{\mathbf{T}}_{I_k}^\kappa {}^I\mathbf{T}_L {}^{L_k}\mathbf{p}_{f_j}; j = 1, \dots, m \quad (40)$$

其中 $\hat{\mathbf{T}}_{I_k}^\kappa$ 是待求的位姿变换。残差的计算和 LOAM 中类似，采用点面距离和点线距离作为残差。定义 \mathbf{u}_j 为平面或边的法向量， ${}^G\mathbf{q}_j$ 是平面或边上的一个点，则残差 \mathbf{z}_j^κ 表示为：

$$\mathbf{z}_j^\kappa = \mathbf{G}_j \left({}^G\hat{\mathbf{p}}_{f_j}^\kappa - {}^G\mathbf{q}_j \right) \quad (41)$$

其中 $\mathbf{G}_j = \mathbf{u}_j^T$ 当面点 p 为平面点， $\mathbf{G}_j = \mathbf{u}_j^\wedge$ 当面点 p 为角点。公式的含义表示点面距离或点线距离，和 LOAM 一致，读者可自行推导。近邻点搜索采用 KD-tree。

3.3.4 Iterated state update

本节开始进行迭代更新。前文说到我们已经完成了 ESKF 的运动方程的线性化，现在我们需要线性化观测方程。其中，观测方程的噪声来自雷达测距的误差，因此对于点 ${}^{L_j}\mathbf{p}_{f_j}$ ，我们定义如下的噪声量：

$${}^{L_j}\mathbf{p}_{f_j}^{\text{gt}} = {}^{L_j}\mathbf{p}_{f_j} - {}^{L_j}\mathbf{n}_{f_j} \quad (42)$$

理论上，如果我们使用状态量的真值 \mathbf{x}_k 以及雷达点的真值 ${}^{L_j}\mathbf{p}_{f_j}^{\text{gt}}$ ，其残差应当为零，把上式代入到残差的计算 (把 (42) 代入到 (39)，再代入到 (40)(41))：

$$\mathbf{0} = \mathbf{h}_j \left(\mathbf{x}_k, {}^{L_j}\mathbf{n}_{f_j} \right) = \mathbf{G}_j \left({}^G\hat{\mathbf{T}}_{I_k} {}^{I_k}\check{\mathbf{T}}_{I_j} {}^I\mathbf{T}_L \left({}^{L_j}\mathbf{p}_{f_j} - {}^{L_j}\mathbf{n}_{f_j} \right) - {}^G\mathbf{q}_j \right) \quad (43)$$

其中 $h(x, n)$ 表示观测方程的函数，这个方程也就是观测方程。我们需要将它线性化，在 $\hat{\mathbf{x}}_k^\kappa$ 附近展开 (即在 $\tilde{\mathbf{x}}_k^\kappa = \mathbf{0}$ 处，因为 $\tilde{\mathbf{x}}_k^\kappa = \mathbf{x}_k \ominus \hat{\mathbf{x}}_k^\kappa$ 或 $\mathbf{x}_k = \hat{\mathbf{x}}_k^\kappa \oplus \tilde{\mathbf{x}}_k^\kappa$)：

$$\begin{aligned} \mathbf{0} &= \mathbf{h}_j \left(\mathbf{x}_k, {}^{L_j}\mathbf{n}_{f_j} \right) = \mathbf{h}_j \left(\hat{\mathbf{x}}_k^\kappa \oplus \tilde{\mathbf{x}}_k^\kappa, {}^{L_j}\mathbf{n}_{f_j} \right) \\ &\simeq \mathbf{h}_j \left(\hat{\mathbf{x}}_k^\kappa, \mathbf{0} \right) + \mathbf{H}_j^\kappa \tilde{\mathbf{x}}_k^\kappa + \mathbf{v}_j \\ &= \mathbf{z}_j^\kappa + \mathbf{H}_j^\kappa \tilde{\mathbf{x}}_k^\kappa + \mathbf{v}_j \end{aligned} \quad (44)$$

其中 \mathbf{H}_j^κ 是 $h(x, n)$ 关于 $\tilde{\mathbf{x}}_k^\kappa$ 的雅可比矩阵 (且取值为 $\tilde{\mathbf{x}}_k^\kappa = 0$), $\mathbf{v}_j \in \mathcal{N}(\mathbf{0}, \mathbf{R}_j)$ 来自于原始测量的噪声 ${}^L_j \mathbf{n}_{f_j}$ 。其中 \mathbf{H} 的计算可以利用链式法则:

$$\mathbf{H} = \frac{\partial \mathbf{h}}{\partial \mathbf{p}} \frac{\partial \mathbf{p}}{\partial \tilde{\mathbf{x}}} \quad (45)$$

其中, \mathbf{p} 表示转换到 $\{\mathbf{G}\}$ 系的特征点。而论文中并没有给出 \mathbf{H} 的详细推导, 此处我们推导一下 \mathbf{H} 的具体形式, 它与代码中的结果是完全相同的。设在 $\{\mathbf{L}\}$ 坐标系下的特征点为 ${}^L \mathbf{p}$, 有以下转换关系:

$$\mathbf{p} = {}^G \hat{\mathbf{R}}_I ({}^L \mathbf{R}_L {}^L \mathbf{p} + {}^L \mathbf{T}_L) + {}^G \hat{\mathbf{T}}_I \quad (46)$$

这里以面点为例 (实际上在 fast-lio2 以及代码中, 都省去了特征提取, 只计算面点的残差), 设 \mathbf{p} 的近邻点所构成的平面的单位法向量为 \vec{n} , 则残差定义为

$$\mathbf{h} = (\mathbf{p} - \mathbf{p}_a) \cdot \vec{n} \quad (47)$$

其中 \mathbf{p}_a 为该平面上的一点。则

$$\frac{\partial \mathbf{h}}{\partial \mathbf{p}} = \vec{n} \quad (48)$$

接下来我们求解 $\frac{\partial \mathbf{p}}{\partial \tilde{\mathbf{x}}}$ 。实际上该矩阵只与 ${}^G \hat{\mathbf{R}}_I$ 和 ${}^G \hat{\mathbf{T}}_I$ 有关, 也就是该矩阵只要求前 6 列, 其他行都为零。即:

$$\frac{\partial \mathbf{p}}{\partial \tilde{\mathbf{x}}} = [-{}^G \hat{\mathbf{R}}_I ({}^L \mathbf{R}_L {}^L \mathbf{p} + {}^L \mathbf{T}_L)^\wedge, I_{3 \times 3}, 0, 0, 0, 0] \quad (49)$$

其中第一项利用了李代数求导的右扰动模型。将以上 2 式相乘即可得到:

$$\mathbf{H} = [-\vec{n} {}^G \hat{\mathbf{R}}_I ({}^L \mathbf{R}_L {}^L \mathbf{p} + {}^L \mathbf{T}_L)^\wedge, \vec{n}, 0, 0, 0, 0] \quad (50)$$

至此我们完成了观测方程的推导。但还并没有到发起总攻的时候。我们现在得到的是 EKF 的表达式, 而文中使用的 IEKF(迭代扩展卡尔曼滤波) 就是在 EKF 进行了改进, 其直接的想法就是在 $x_k \rightarrow x_{k+1}$ 的过程中进行多次迭代, 以达到消减非线性的影响 (关于 IEKF 读者可参考 [7])。这里比较有意思的是, IEKF 可以证明和高斯牛顿 GN 法是等价的, 因此 IEKF 可以保证全局收敛 ([8] 中证明了文中的 IEKF 和 GN 是等价的)。

在 IEKF 中, 迭代过程不会更新协方差矩阵 \mathbf{P} 。而文中用了如下公式, 使得我们在迭

代过程中也能够更新协方差矩阵：

$$\tilde{\mathbf{x}}_k = \mathbf{x}_k \boxminus \hat{\mathbf{x}}_k = (\hat{\mathbf{x}}_k^\kappa \boxplus \tilde{\mathbf{x}}_k^\kappa) \boxminus \hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^\kappa \boxminus \hat{\mathbf{x}}_k + \mathbf{J}^\kappa \tilde{\mathbf{x}}_k^\kappa \quad (51)$$

其中：

$$\mathbf{J}^\kappa = \begin{bmatrix} \mathbf{A} \left({}^G \widehat{\mathbf{R}}_{I_k}^\kappa \boxminus {}^G \widehat{\mathbf{R}}_{I_k} \right)^{-T} & \mathbf{0}_{3 \times 15} \\ \mathbf{0}_{15 \times 3} & \mathbf{I}_{15 \times 15} \end{bmatrix} \quad (52)$$

为雅可比矩阵，上式同样是通过式 (26) 推导而来。由于每迭代一次后 $\tilde{\mathbf{x}}$ 就会发生一次变化，理论上其协方差矩阵并不是初始的 \mathbf{P}_k 了，因此协方差矩阵可通过 $\mathbf{P} = (\mathbf{J}^\kappa)^{-1} \hat{\mathbf{P}}_k (\mathbf{J}^\kappa)^{-T}$ 在迭代过程中更新。可以看到该矩阵实际上也是接近单位阵的。

至此，我们完成了 ESKF 的所有前置任务。最大后验估计：

$$\min_{\tilde{\mathbf{x}}_k^\kappa} \left(\|\mathbf{x}_k \boxminus \hat{\mathbf{x}}_k\|_{\hat{\mathbf{P}}_k^{-1}}^2 + \sum_{j=1}^m \left\| \mathbf{z}_j^\kappa + \mathbf{H}_j^\kappa \tilde{\mathbf{x}}_k^\kappa \right\|_{\mathbf{R}_j^{-1}}^2 \right) \quad (53)$$

令 $\mathbf{H} = [\mathbf{H}_1^{\kappa T}, \dots, \mathbf{H}_m^{\kappa T}]^T$, $\mathbf{R} = \text{diag}(\mathbf{R}_1, \dots, \mathbf{R}_m)$, $\mathbf{P} = (\mathbf{J}^\kappa)^{-1} \hat{\mathbf{P}}_k (\mathbf{J}^\kappa)^{-T}$, 以及 $\mathbf{z}_k^\kappa = [\mathbf{z}_1^{\kappa T}, \dots, \mathbf{z}_m^{\kappa T}]^T$, 则卡尔曼增益：

$$\mathbf{K} = \mathbf{P} \mathbf{H}^T (\mathbf{H} \mathbf{P} \mathbf{H}^T + \mathbf{R})^{-1} \quad (54)$$

迭代公式：

$$\hat{\mathbf{x}}_k^{\kappa+1} = \hat{\mathbf{x}}_k^\kappa \boxplus \left(-\mathbf{K} \mathbf{z}_k^\kappa - (\mathbf{I} - \mathbf{K} \mathbf{H}) (\mathbf{J}^\kappa)^{-1} (\hat{\mathbf{x}}_k^\kappa \boxminus \hat{\mathbf{x}}_k) \right) \quad (55)$$

接下来我们推导这个公式 (参考了 [8])。省略掉下标 k , 令 $X = \hat{\mathbf{x}}^\kappa \boxminus \hat{\mathbf{x}}$, 式 (53) 总误差可以表示为如下的最小二乘的形式：

$$E = \min_{\tilde{x}^\kappa} \frac{1}{2} \begin{pmatrix} z^\kappa + H \tilde{x}^\kappa \\ X + J^\kappa \tilde{x}^\kappa \end{pmatrix}^T \begin{pmatrix} R & \\ & \hat{P} \end{pmatrix}^{-1} \begin{pmatrix} z^\kappa + H \tilde{x}^\kappa \\ X + J^\kappa \tilde{x}^\kappa \end{pmatrix} = \min_{\tilde{x}^\kappa} \frac{1}{2} M^T M \quad (56)$$

其中

$$M = S \begin{pmatrix} z^\kappa + H \tilde{x}^\kappa \\ X + J^\kappa \tilde{x}^\kappa \end{pmatrix}, S^T S = \begin{pmatrix} R & \\ & \hat{P} \end{pmatrix}^{-1} \quad (57)$$

$X + J^\kappa \tilde{x}^\kappa$ 由式 (51) 得来。显然 M 关于 \tilde{x}^κ 的雅可比为：

$$\mathcal{J} = S \begin{pmatrix} H \\ J^\kappa \end{pmatrix} \quad (58)$$

根据高斯牛顿法，每次迭代的增量：

$$\Delta \tilde{x}^\kappa = -(\mathcal{J}^T \mathcal{J})^{-1} \mathcal{J}^T M \quad (59)$$

对其分别推导，其中：

$$\begin{aligned} (\mathcal{J}^T \mathcal{J})^{-1} &= \left[\begin{pmatrix} H^T & J^{\kappa T} \end{pmatrix} \begin{pmatrix} R^{-1} & \\ & \hat{P}^{-1} \end{pmatrix} \begin{pmatrix} H \\ J^\kappa \end{pmatrix} \right]^{-1} \\ &= (J^{\kappa T} \hat{P}^{-1} J^\kappa + H^T R^{-1} H)^{-1} \\ &\stackrel{SMW}{=} P - PH^T (R + HPH^T)^{-1} HP \\ &= (I - KH)P \\ &= KRH^{-T} \end{aligned} \quad (60)$$

其中 $P = J^{\kappa-1} \hat{P} J^{\kappa-T}$, $K = PH^T (HPH^T + R)^{-1}$ 。第三行利用了 SMW 公式：

$$(A^{-1} + BD^{-1}C)^{-1} = A - AB(D + CAB)^{-1}CA \quad (61)$$

最后一行推导如下：

$$\begin{aligned} K &= PH^T (HPH^T + R)^{-1} \\ K(HPH^T + R) &= PH^T \\ KR - (I - KH)PH^T &= 0 \\ (I - KH)P &= KRH^{-T} \end{aligned} \quad (62)$$

回到式 (59), 后面部分：

$$\begin{aligned} -\mathcal{J}^T M &= - \begin{pmatrix} H^T & J^{\kappa T} \end{pmatrix} \begin{pmatrix} R^{-1} & \\ & \hat{P}^{-1} \end{pmatrix} \begin{pmatrix} z^\kappa + H\tilde{x}^\kappa \\ X + J^\kappa \tilde{x}^\kappa \end{pmatrix} \\ &= -H^T R^{-1} (z^\kappa + H\tilde{x}^\kappa) - J^{\kappa T} \hat{P}^{-1} (X + J^\kappa \tilde{x}^\kappa) \end{aligned} \quad (63)$$

式 (60) 和式 (63) 相乘，得：

$$\begin{aligned} \Delta \tilde{x}^\kappa &= KRH^{-T} (-H^T R^{-1} (z^\kappa + H\tilde{x}^\kappa)) - (I - KH)P (J^{\kappa T} \hat{P}^{-1} (X + J^\kappa \tilde{x}^\kappa)) \\ &= -Kz^\kappa - KH\tilde{x}^\kappa - (I - KH)J^{\kappa-1} \hat{P} J^{\kappa-T} (J^{\kappa T} \hat{P}^{-1} (X + J^\kappa \tilde{x}^\kappa)) \\ &= -Kz^\kappa - KH\tilde{x}^\kappa - (I - KH)J^{\kappa-1} (X + J^\kappa \tilde{x}^\kappa) \\ &= -Kz^\kappa - \tilde{x}^\kappa - (I - KH)J^{\kappa-1} X \end{aligned} \quad (64)$$

则

$$\tilde{\mathbf{x}}^{\kappa+1} = \tilde{\mathbf{x}}^{\kappa} + \Delta\tilde{\mathbf{x}}^{\kappa} = -\mathbf{K}\mathbf{z}^{\kappa} - (\mathbf{I} - \mathbf{K}\mathbf{H})\mathbf{J}^{\kappa-1}(\hat{\mathbf{x}}^{\kappa} \boxminus \hat{\mathbf{x}}) \quad (65)$$

推导完毕！可以看出 ESKF 和 GN 法是等效的。

最后，文中提到了一个工程问题，在计算卡尔曼增益时，矩阵 $\mathbf{H}\mathbf{P}\mathbf{H}^T + \mathbf{R}$ 的维度是很大的 ($m \times m$, 因为 $H_{m \times 18}, P_{18 \times 18}, R_{m \times m}$)，特征点 m 的数量可能为上千个，如此高维的矩阵求逆是十分耗时的，因此文中给出了新的卡尔曼增益计算方式，它和原增益是等效的：

$$\mathbf{K} = (\mathbf{H}^T\mathbf{R}^{-1}\mathbf{H} + \mathbf{P}^{-1})^{-1} \mathbf{H}^T\mathbf{R}^{-1} \quad (66)$$

证明是易懂的，见文中附录及 [9]。式中 $\mathbf{H}^T\mathbf{R}^{-1}\mathbf{H}$ 是 18×18 的，避免了高维矩阵求逆的情况。

3.3.5 The algorithm

算法总结如图 7 所示。

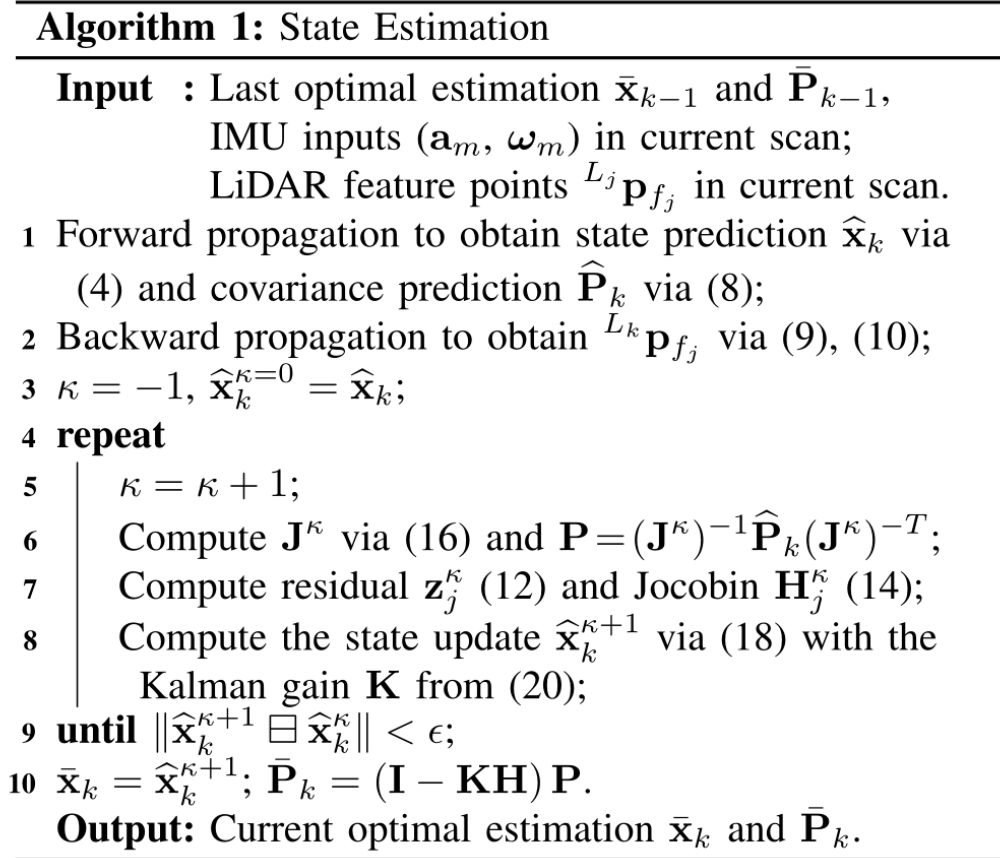


Figure 7: 算法总结.

3.4 Map Update

地图的更新就是根据估计的最优状态变量 $\bar{\mathbf{x}}_k$ (写成 SE(3): ${}^G\bar{\mathbf{T}}_{I_k} = ({}^G\bar{\mathbf{R}}_{I_k}, {}^G\bar{\mathbf{p}}_{I_k})$) 把特征点全部投影到全局坐标系:

$${}^G\bar{\mathbf{p}}_{f_j} = {}^G\bar{\mathbf{T}}_{I_k} {}^I\mathbf{T}_L {}^L\mathbf{p}_{f_j}; j = 1, \dots, m. \quad (67)$$

3.5 Initialization

初始化: 在开始时刻保持 2s, 利用收集到的数据初始化重力向量, IMU 零偏, 噪声等

4 EXPERIMENT RESULTS

4.1 Computational Complexity Experiments

- Table II 两种卡尔曼增益计算效率对比, 明显新公式提升较大

4.2 UAV Flight Experiments

- 无人机实验
- 70°FOV Livox LiDAR, DJI Manifold 2-C 1.8 GHz Intel i7-8550U CPU
- 最大 50HZ 的里程计输出 + 建图
- 漂移小于 0.3% (32 米轨迹上的漂移为 0.08 米)。

4.3 Indoor Experiments

- 室内手持快速旋转的场景 ($>100^\circ/\text{s}$)
- 与 LOAM 对比, 紧耦合 vs 松耦合

4.4 Outdoor Experiments

- 室外手持, 香港大学主楼
- 漂移小于 0.05% (140 米轨迹上的漂移为 0.07 米), 10HZ, 平均处理时间为 25ms, 平均有效特征点为 1497 个

- 在 LINS 数据集上比较, FAST-LIO 平均 7.3ms, LINS 平均 34.5ms(个人感觉理论上的差异主要在计算增益 K 的公式上)

References

- [1] FAST-LIO: A Fast, Robust LiDAR-inertial Odometry Package by Tightly-Coupled Iterated Kalman Filter.
- [2] 流形-Manifold 学习理解与应用. <https://www.cnblogs.com/icmzn/p/11082509.html>.
- [3] Kalman Filters on Differentiable Manifolds.
- [4] 从零开始的 IMU 状态模型推导: https://fzheng.me/2016/11/20/imu_model_eq.
- [5] 简明 ESKF 推导: <https://zhuanlan.zhihu.com/p/441182819>
- [6] Quaternion kinematics for the error-state Kalman filter.
- [7] 迭代扩展卡尔曼滤波 (IEKF): <https://zhuanlan.zhihu.com/p/141018958>
- [8] FAST-LIO2 简明公式推导:<https://zhuanlan.zhihu.com/p/533920262>
- [9] 关于 FAST-LIO 中使用卡尔曼滤波增益更新求逆简化问题推导:
https://blog.csdn.net/weixin_44023934/article/details/123506688